ASSIGNMENT 2 / DEEP LEARNING

Transfer Learning · TensorFlow Flowers

Порівняльне дослідження pretrained CNN-екстракторів та класичних класифікаторів. Матеріали для Jupyter і захисту.

Фактичний запуск: 31.10.2026 (основний запуск) та 01.11.2026 (розширення: VGG16 і додаткові режими заморожування). Команда: три учасники. Python 3.12 · TensorFlow CPU 2.20 · scikit-learn 1.8.

Показник	Результат
Дані	3670 фото / 5 класів / 2569–550–551
Класичні кандидати	3 CNN × 3 класифікатори = 9 пар
Режими заморожування	last 0, last 10, last 20, last 35, last 50, last 75, last 100, last 115, усі шари
Test класичної пари	89.84% · ResNet50 + SVM RBF · вибір за validation
Test вибраної CNN	91.83% · MobileNetV2 усі шари
Перевірки	103 пройдено / 36 PNG / збережені моделі

Умови викладача

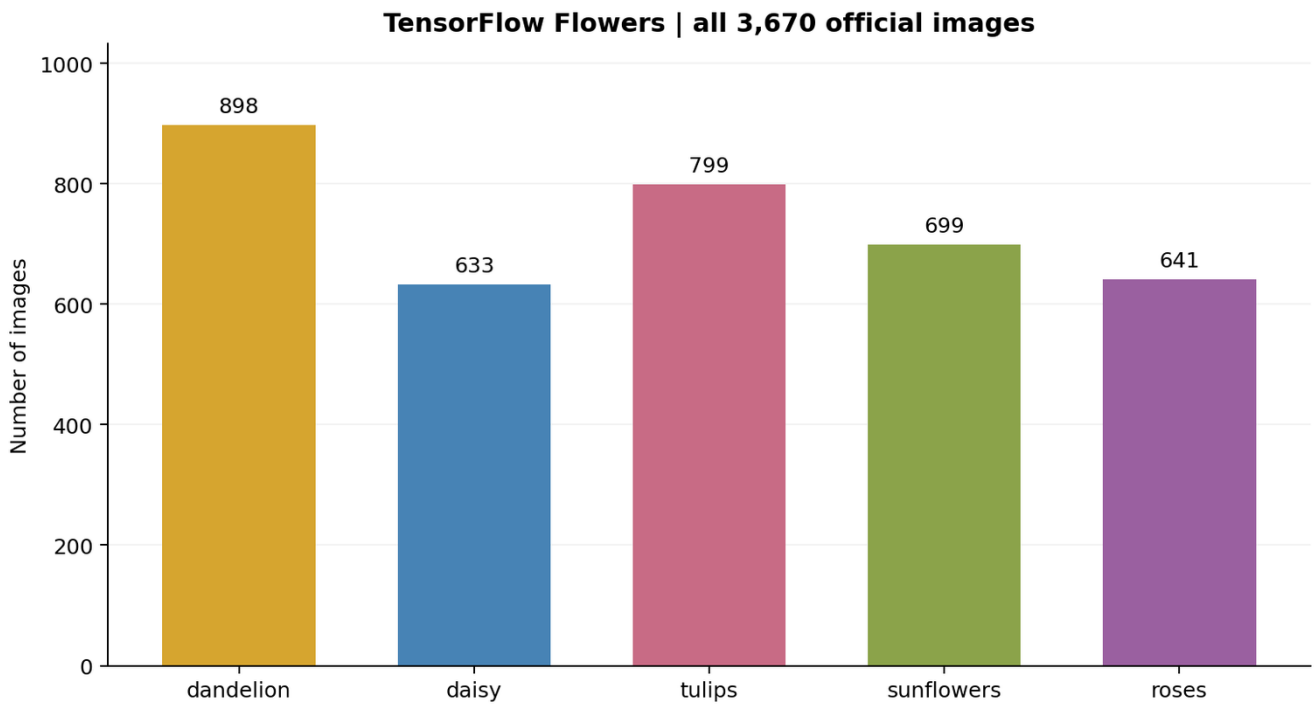
Слайд 14: порівняти кілька класифікаторів на кількох екстракторах; дослідити залежність accuracy від глибини заморожених шарів; побудувати confusion matrices і показати typical errors. Оцінювання: матриці 60%, тренд 20%, помилки 20%.

Звіт містить фактичні результати. В архіві є повний код, два виконані notebook, усі графіки й таблиці. Статистичну універсальну перевагу моделі за одним split не стверджуємо.

1. Дані та контроль split

TensorFlow Flowers: dandelion 898, daisy 633, tulips 799, sunflowers 699, roses 641. Власний grouped stratified split, seed 42. Назви міток узято з TFDS; JPEG - із того самого офіційного архіву.

class_name	train	val	test
dandelion	628	135	135
daisy	443	95	95
tulips	559	120	120
sunflowers	490	104	105
roses	449	96	96

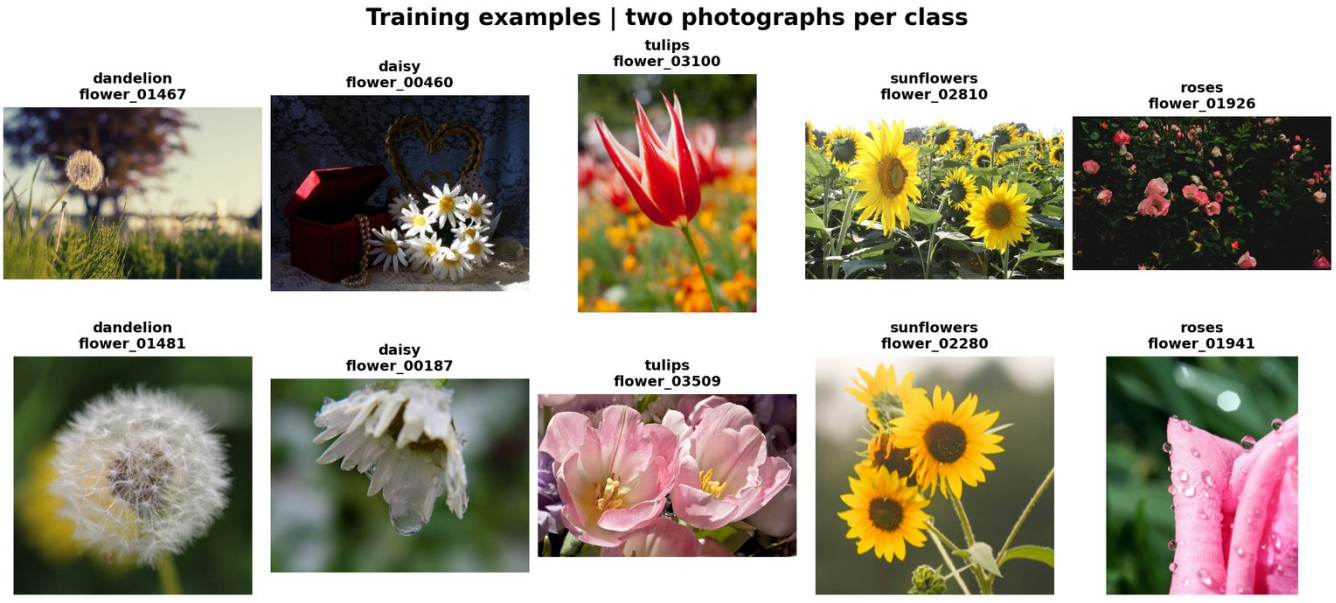


Знайдено 3667 унікальних побайтових хешів: 3 пари дублікатів. Одна пара має мітки roses і tulips. Збережено всі офіційні записи й labels; стратифікація виконується на групах SHA-256, тож однаковий файл не перетинає split.

Розбиття: 2569 train / 550 validation / 551 test, seed 42. Спільний manifest незмінний для всіх моделей. Майже-дублікати не усувалися вичерпно.

Manifest SHA-256: a10282424e8d9cd6e5097494357155ee29721f266ed81f409dbe548d3c255893

2. Приклади, баланс і розміри



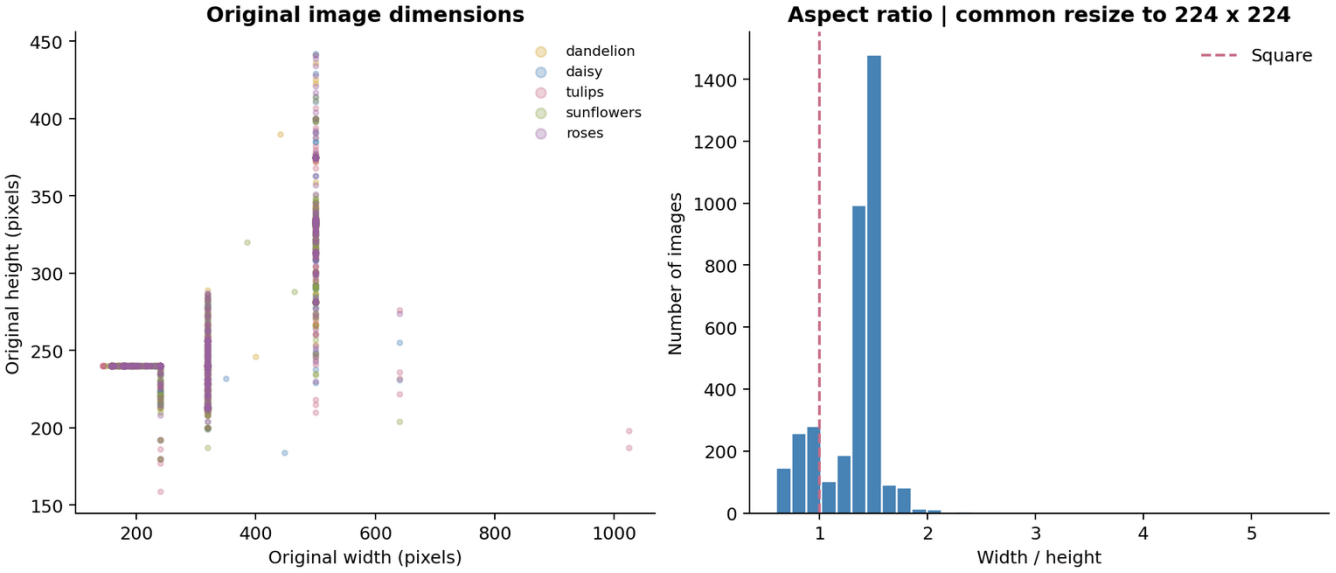


Фото мають різні пропорції, ракурси й фони. Єдине resize до 224×224 забезпечує однаковий протокол, але може змінювати форму. Дисбаланс класів помірний, тому разом із accuracy показано macro-F1.

Зображення: офіційний TensorFlow Flowers; атрибуція всіх фото включена у data/FLOWERS_LICENSE.txt.

3. Моделі та експериментальний протокол

Feature extraction: ImageNet backbone без початкової голови + Global Average Pooling. MobileNetV2 формує 1280 ознак, ResNet50 формує 2048 ознак, VGG16 формує 512 ознак. Усі отримують RGB фото після resize до 224×224 без збереження пропорцій: це узгоджений базовий протокол, можливі спотворення форми.

MobileNetV2 preprocess_input масштабує значення до [-1, 1]; ResNet50 і VGG16 preprocess_input переставляють RGB у BGR і центрують за середніми ImageNet. CNN не навчаються під час отримання ознак. IDs зберігаються разом із X та y.

Logistic Regression: StandardScaler + C=1, max_iter=3000, lbfgs. SVM: StandardScaler + RBF, C=1, gamma=scale, probability=True. Random Forest: 300 дерев, max_features=sqrt, seed 42. Усі fit тільки на train, scaler теж train-only. Гіперпараметри задані до test.

Найкраща класична пара обирається серед 9 кандидатів за validation macro-F1, потім accuracy. Вибір записується перед test-прогнозами. Test-результати всіх пар - підсумковий benchmark, а не критерій перевибору.

Accuracy - частка правильних прогнозів; macro-F1 - середнє F1 п’яти класів із рівними вагами; weighted-F1 враховує чисельність класів. Raw confusion matrix містить кількості, row-normalized - частки в межах істинного класу.

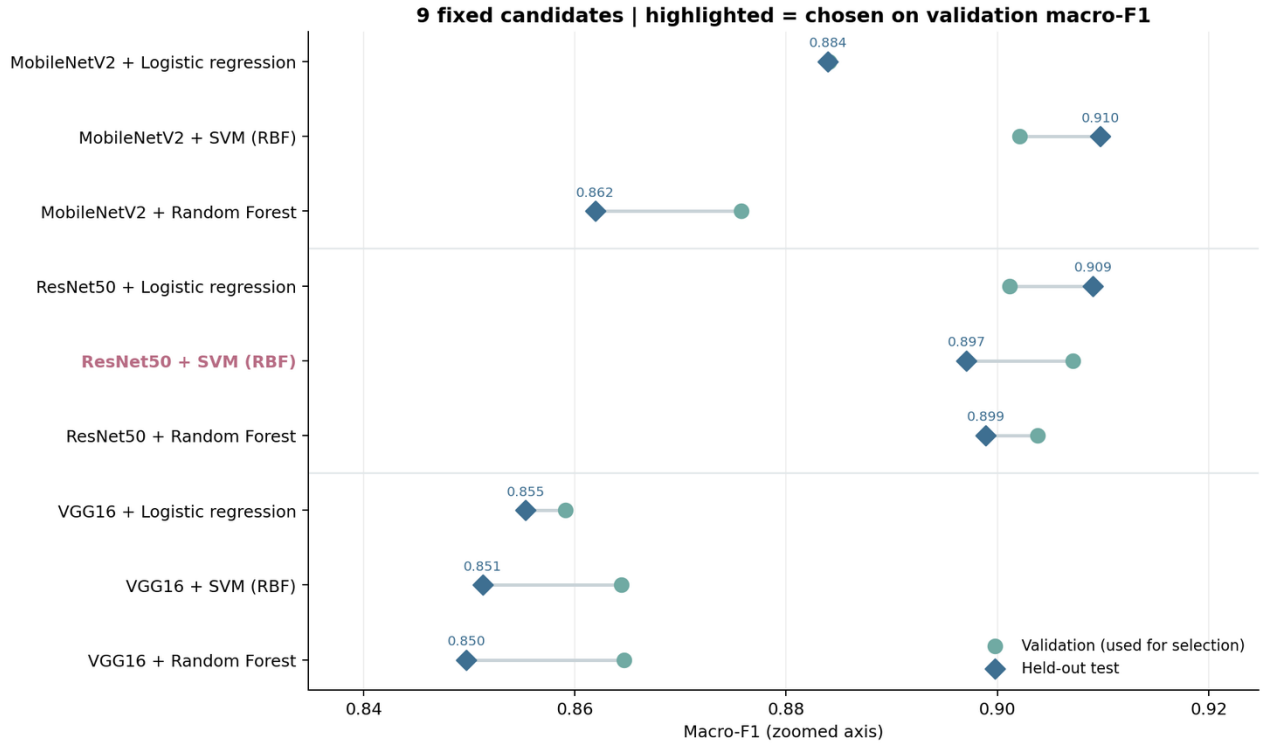
Методика оцінювання

Train визначає ваги й scaler. Validation визначає переможця й checkpoint. Test залишається незалежним до фіксації вибору. Один manifest використано для всіх класичних пар і всіх режимів CNN.

SVM confidence обчислюється з predict_proba для фактичного класу predict; ці два правила в SVC не завжди мають один argmax. Probability не є гарантією правильності.

4. Порівняння 9 кандидатів

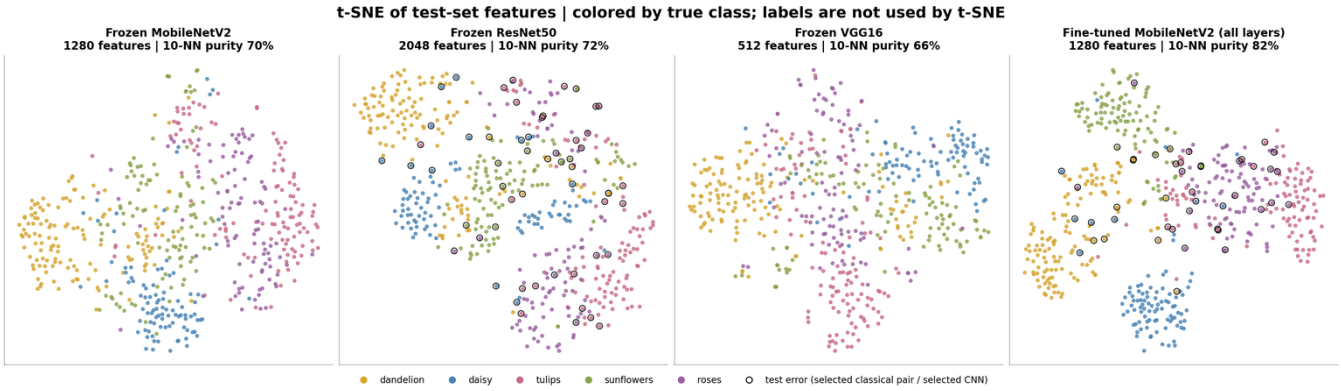
Екстрактор	Класифікатор	Val acc	Val F1	Test acc	Test F1
MobileNetV2	Logistic Regression	88.73%	0.8840	88.57%	0.8839
MobileNetV2	SVM RBF	90.36%	0.9021	91.11%	0.9097
MobileNetV2	Random Forest	87.82%	0.8757	86.39%	0.8619
ResNet50	Logistic Regression	90.36%	0.9012	91.11%	0.9091
ResNet50	SVM RBF	90.91%	0.9071	89.84%	0.8971
ResNet50	Random Forest	90.55%	0.9038	90.02%	0.8989
VGG16	Logistic Regression	86.18%	0.8591	85.84%	0.8553
VGG16	SVM RBF	86.55%	0.8644	85.48%	0.8513
VGG16	Random Forest	86.55%	0.8646	85.30%	0.8497



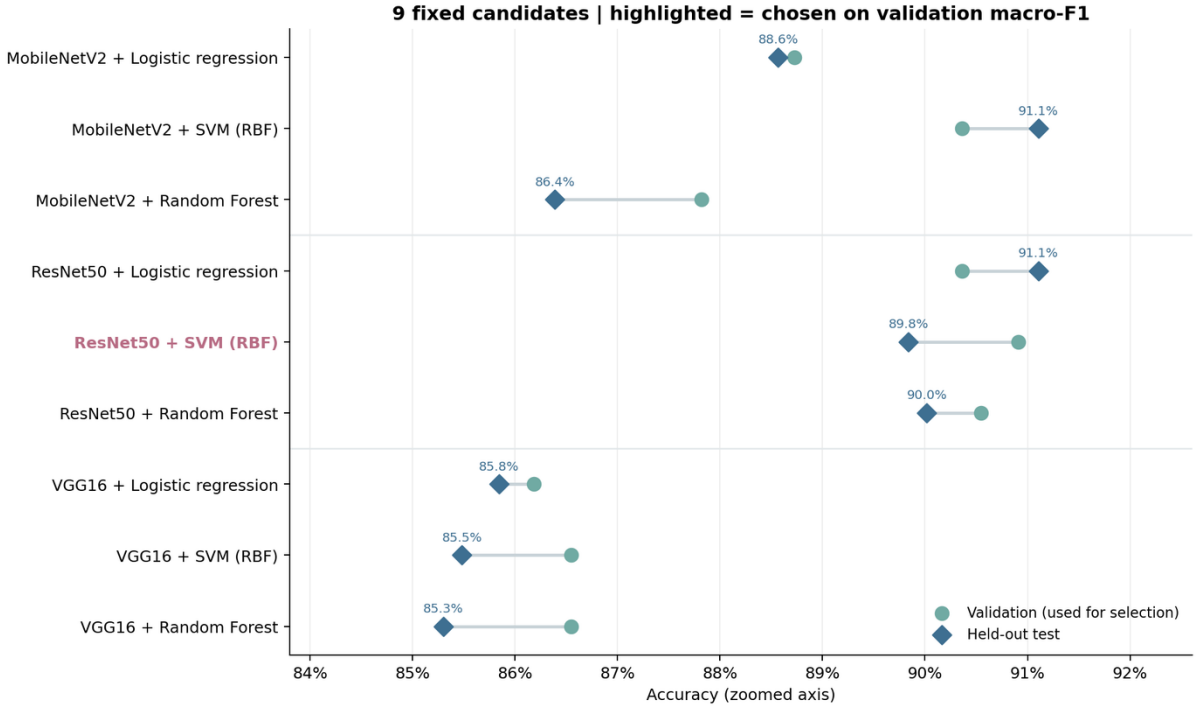
За validation macro-F1 вибрано ResNet50 + SVM RBF. Його test accuracy 89.84%, macro-F1 0.8971.

Найвища test accuracy серед фіксованих кандидатів - 91.11% у MobileNetV2 + SVM RBF та ResNet50 + Logistic Regression. Це описовий підсумок; переможця за validation не перевибираємо. Середня accuracy validation / test за трьома класифікаторами: ResNet50 90.61% / 90.32%, MobileNetV2 88.97% / 88.69% та VGG16 86.42% / 85.54%. Середня accuracy за трьома екстракторами: SVM RBF 89.27% / 88.81%, Logistic Regression 88.42% / 88.51% та Random Forest 88.30% / 87.24%.

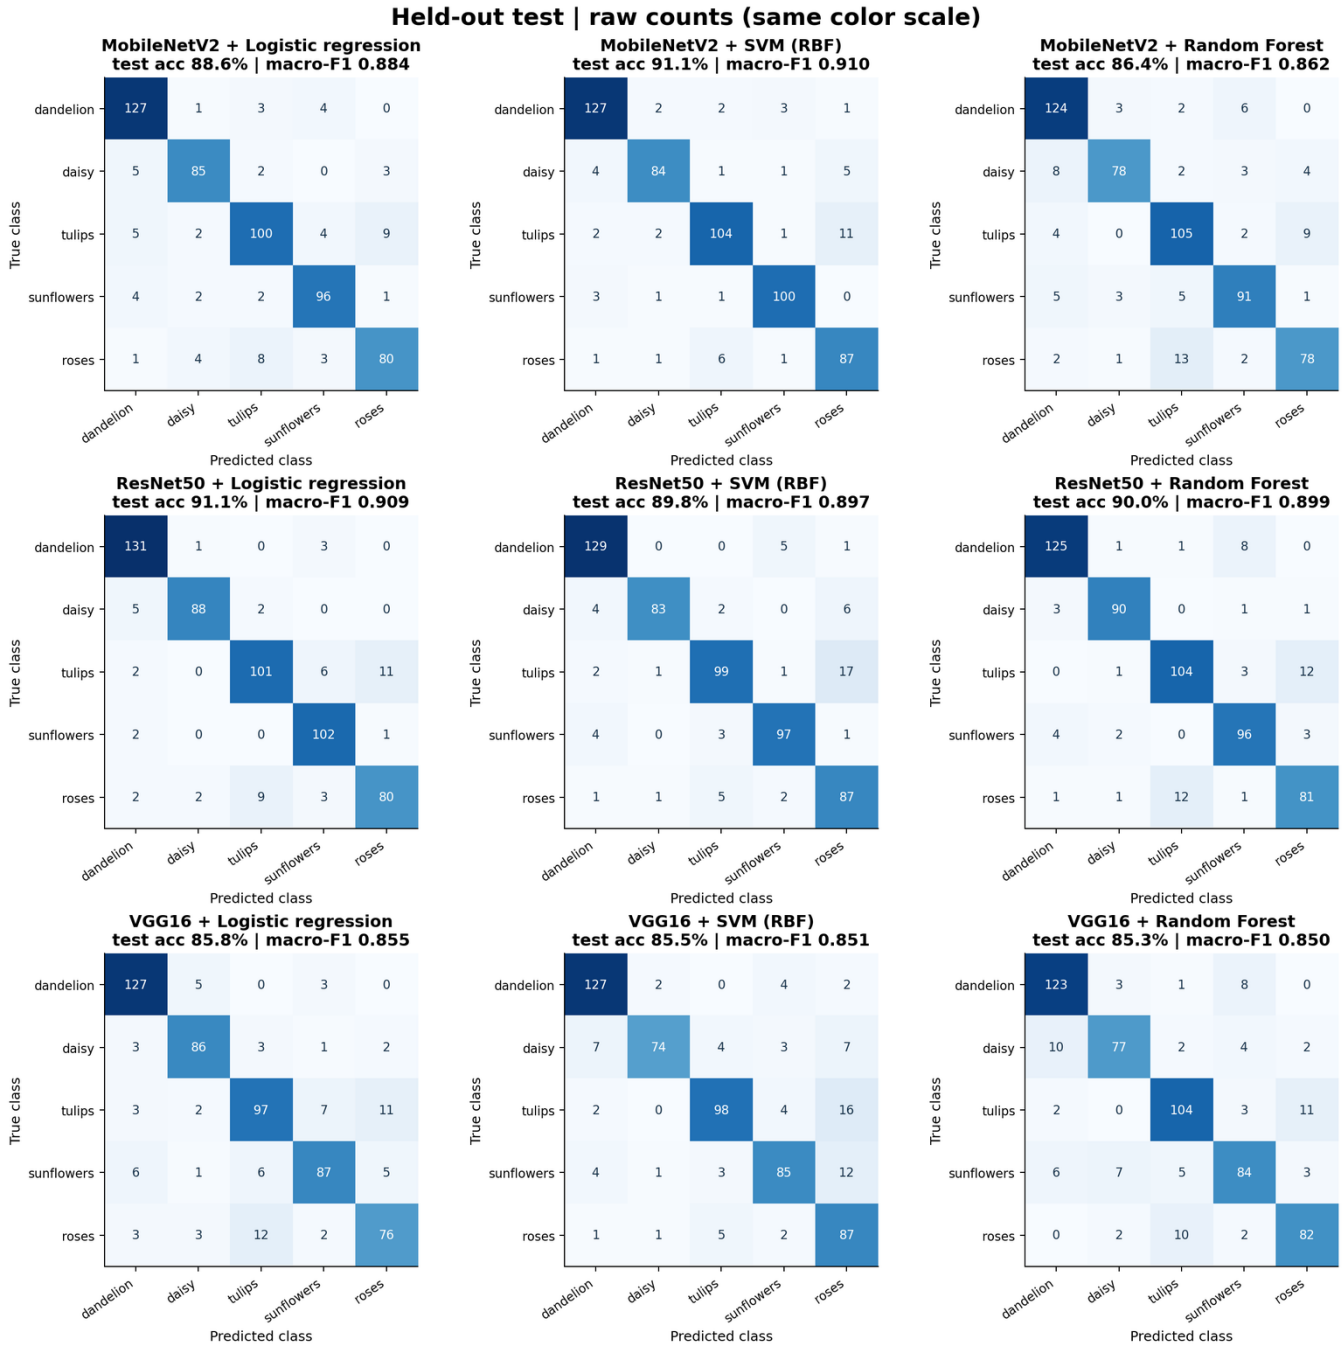
5. t-SNE ознак трьох CNN



t-SNE проєктує тестові ознаки у 2D без використання міток; колір - справжній клас. Частка 10 найближчих сусідів того самого класу на площині (описова «чистота» кластерів): MobileNetV2 70%, ResNet50 72% та VGG16 66%; після донавчання MobileNetV2 - 82%. Fine-tuning робить класи компактнішими, ніж заморожені ImageNet-ознаки. Тюльпани й троянди перекриваються найбільше; кружками позначено тестові помилки обраних моделей. t-SNE - ілюстрація, а не метрика якості.

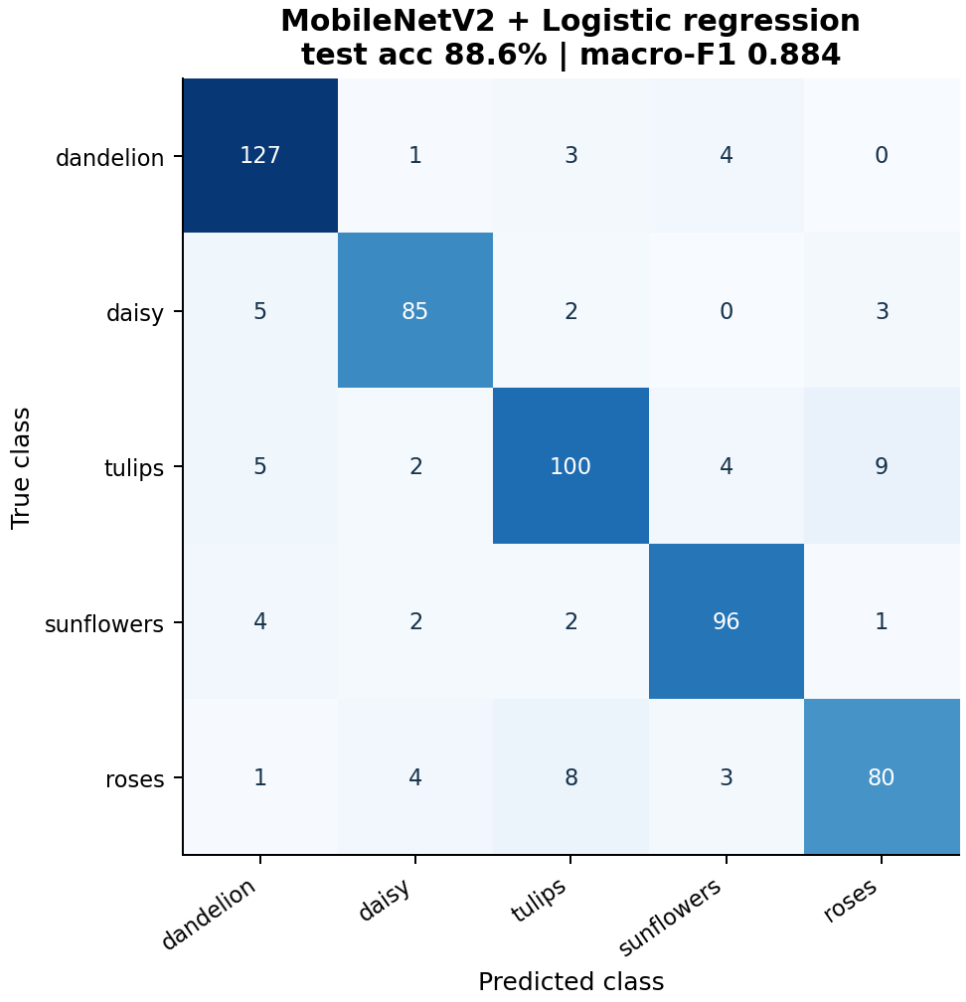


6. Матриці помилок: огляд



Рядок - справжній клас, стовпець - прогноз. Однакова шкала кольору для всіх raw-матриць. Нижче - кожна пара окремо зі звітом за класами.

Матриця: MobileNetV2 + Logistic Regression

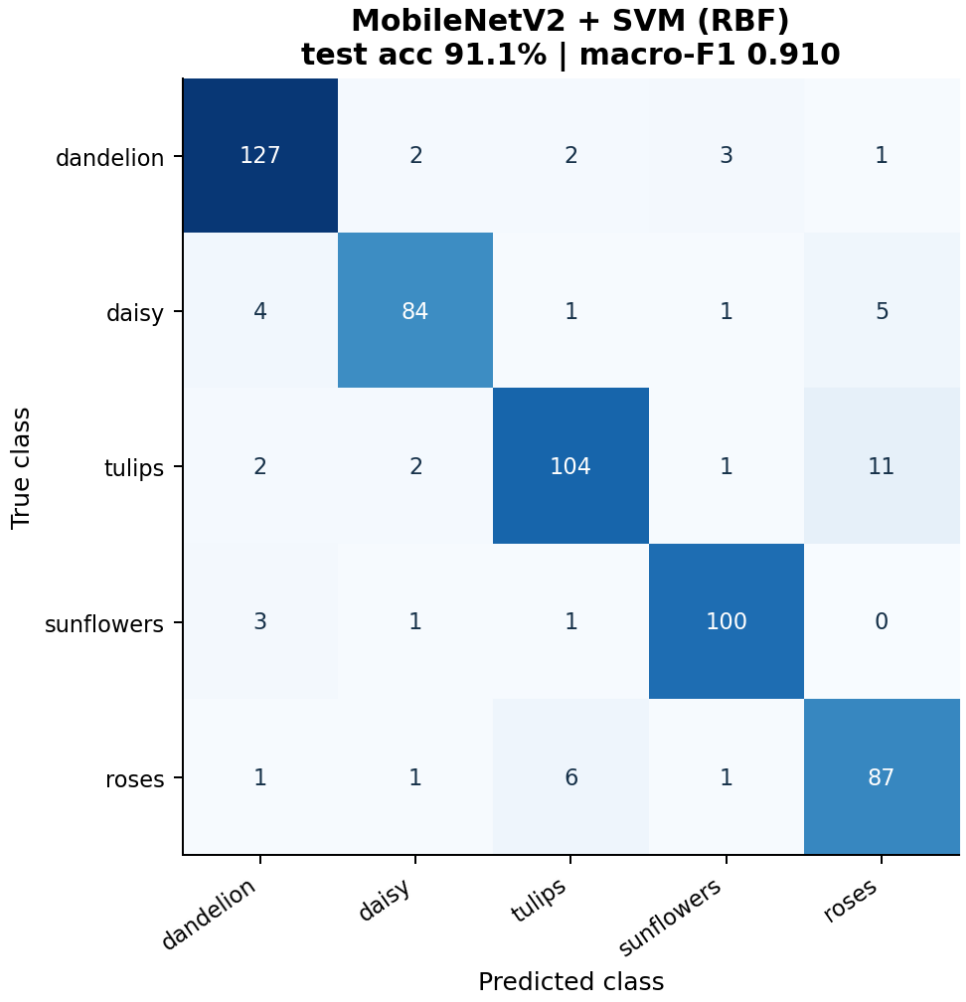


Test: accuracy 88.57%; macro-F1 0.8839; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.8944	0.9407	0.9170	135
daisy	0.9043	0.8947	0.8995	95
tulips	0.8696	0.8333	0.8511	120
sunflowers	0.8972	0.9143	0.9057	105
roses	0.8602	0.8333	0.8466	96

Row-normalized версія: confusion_normalized_mobilenetv2_logreg.png. Її діагональ - recall класу.

Матриця: MobileNetV2 + SVM RBF

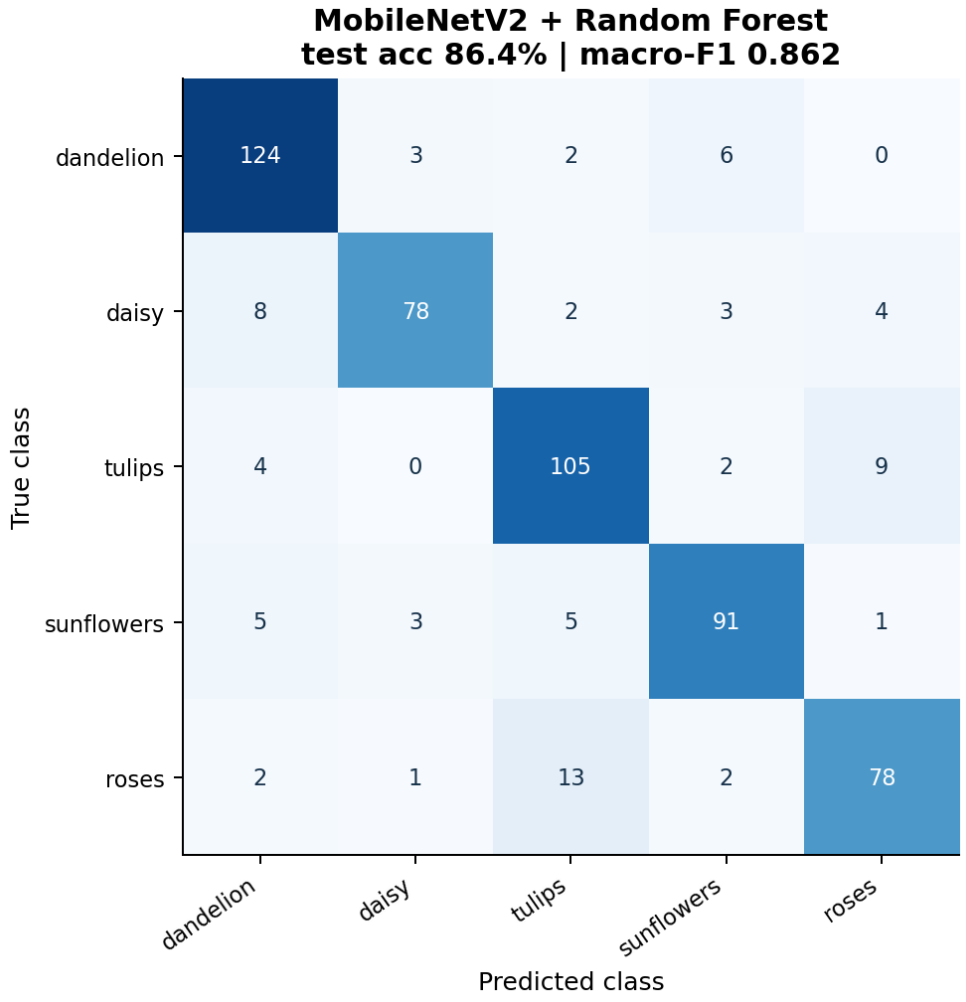


Test: accuracy 91.11%; macro-F1 0.9097; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.9270	0.9407	0.9338	135
daisy	0.9333	0.8842	0.9081	95
tulips	0.9123	0.8667	0.8889	120
sunflowers	0.9434	0.9524	0.9479	105
roses	0.8365	0.9062	0.8700	96

Row-normalized версія: confusion_normalized_mobilenetv2_svm.png. Її діагональ - recall класу.

Матриця: MobileNetV2 + Random Forest

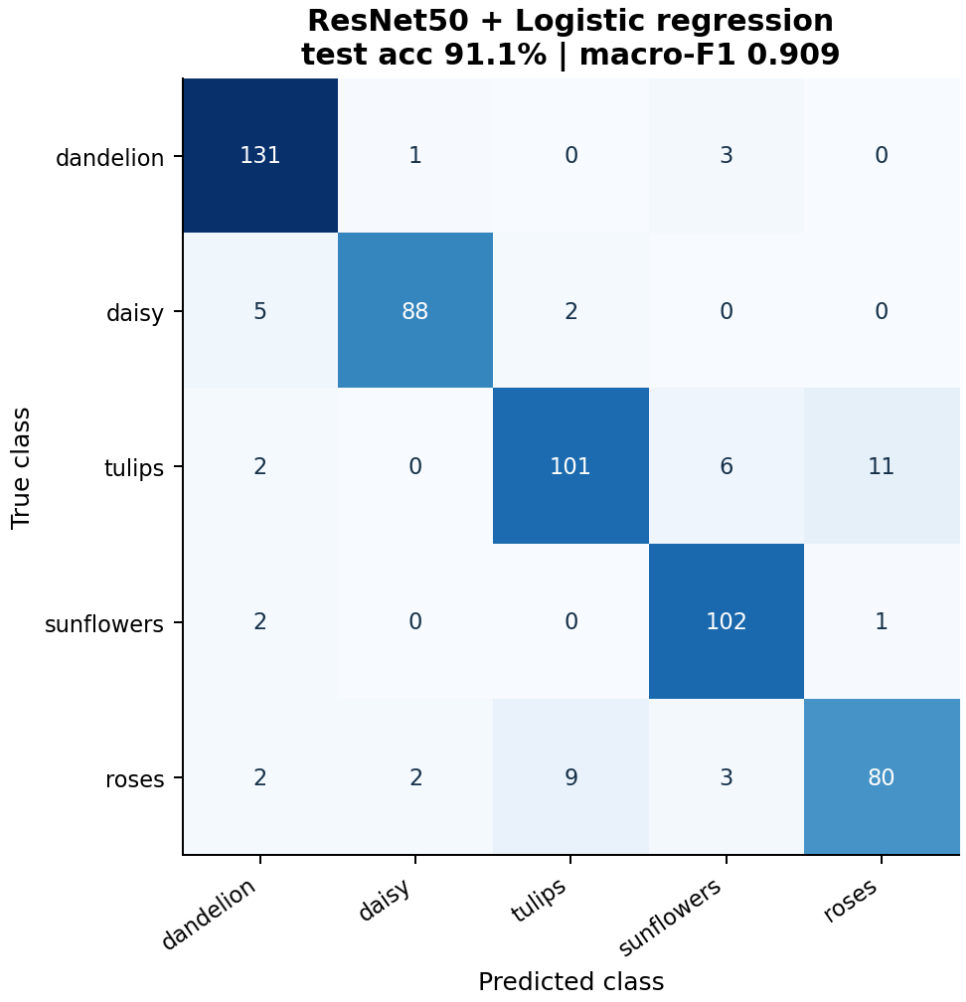


Test: accuracy 86.39%; macro-F1 0.8619; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.8671	0.9185	0.8921	135
daisy	0.9176	0.8211	0.8667	95
tulips	0.8268	0.8750	0.8502	120
sunflowers	0.8750	0.8667	0.8708	105
roses	0.8478	0.8125	0.8298	96

Row-normalized версія: confusion_normalized_mobilenetv2_randomforest.png. Її діагональ - recall класу.

Матриця: ResNet50 + Logistic Regression

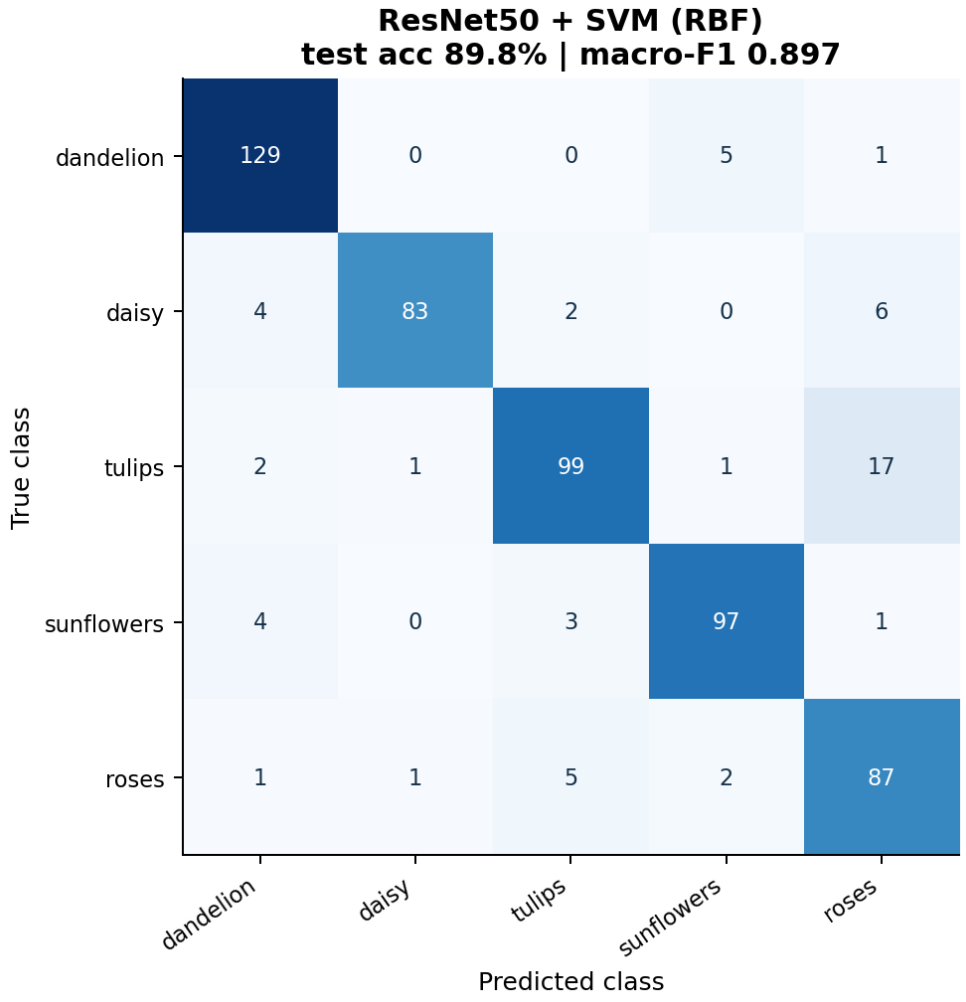


Test: accuracy 91.11%; macro-F1 0.9091; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.9225	0.9704	0.9458	135
daisy	0.9670	0.9263	0.9462	95
tulips	0.9018	0.8417	0.8707	120
sunflowers	0.8947	0.9714	0.9315	105
roses	0.8696	0.8333	0.8511	96

Row-normalized версія: confusion_normalized_resnet50_logreg.png. Її діагональ - recall класу.

Матриця: ResNet50 + SVM RBF

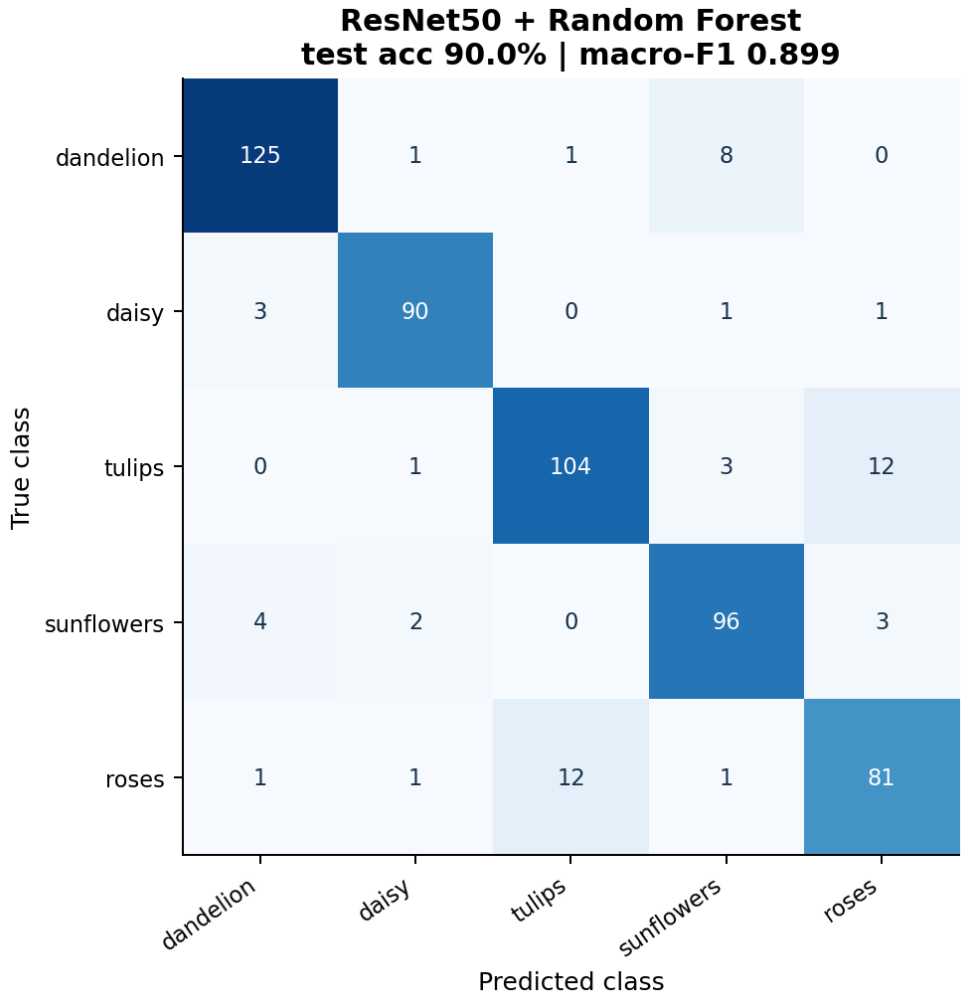


Test: accuracy 89.84%; macro-F1 0.8971; n=551. Рядок - справжній клас, стовпець - прогноз. Обрана за validation.

Клас	precision	recall	f1-score	support
dandelion	0.9214	0.9556	0.9382	135
daisy	0.9765	0.8737	0.9222	95
tulips	0.9083	0.8250	0.8646	120
sunflowers	0.9238	0.9238	0.9238	105
roses	0.7768	0.9062	0.8365	96

Row-normalized версія: confusion_normalized_resnet50_svm.png. Її діагональ - recall класу.

Матриця: ResNet50 + Random Forest

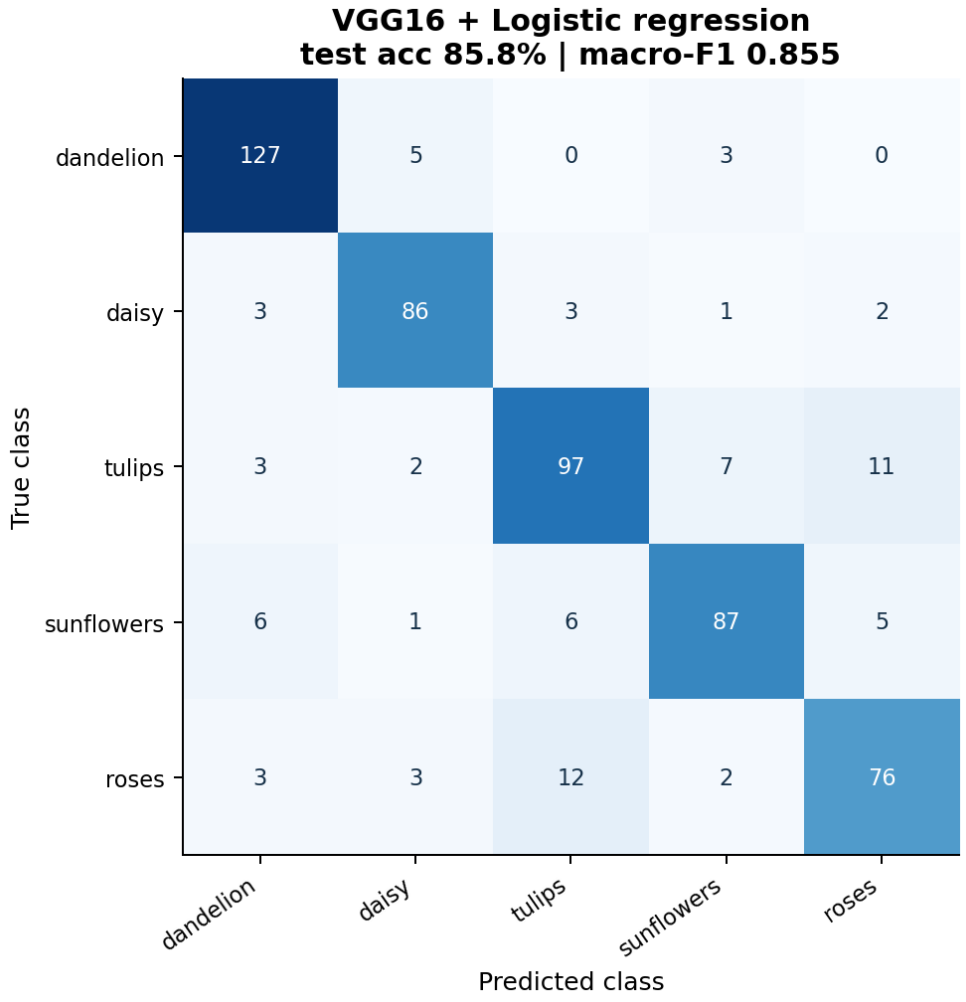


Test: accuracy 90.02%; macro-F1 0.8989; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.9398	0.9259	0.9328	135
daisy	0.9474	0.9474	0.9474	95
tulips	0.8889	0.8667	0.8776	120
sunflowers	0.8807	0.9143	0.8972	105
roses	0.8351	0.8438	0.8394	96

Row-normalized версія: confusion_normalized_resnet50_randomforest.png. Її діагональ - recall класу.

Матриця: VGG16 + Logistic Regression

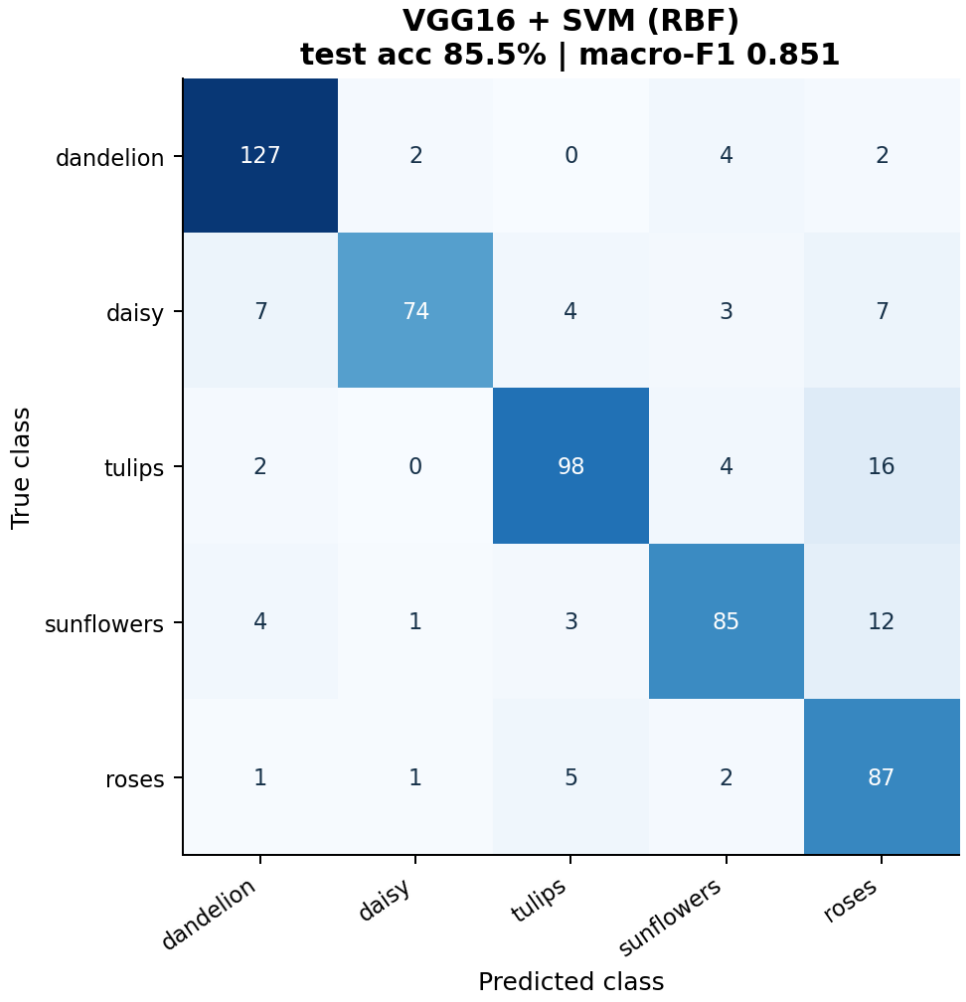


Test: accuracy 85.84%; macro-F1 0.8553; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.8944	0.9407	0.9170	135
daisy	0.8866	0.9053	0.8958	95
tulips	0.8220	0.8083	0.8151	120
sunflowers	0.8700	0.8286	0.8488	105
roses	0.8085	0.7917	0.8000	96

Row-normalized версія: confusion_normalized_vgg16_logreg.png. Її діагональ - recall класу.

Матриця: VGG16 + SVM RBF

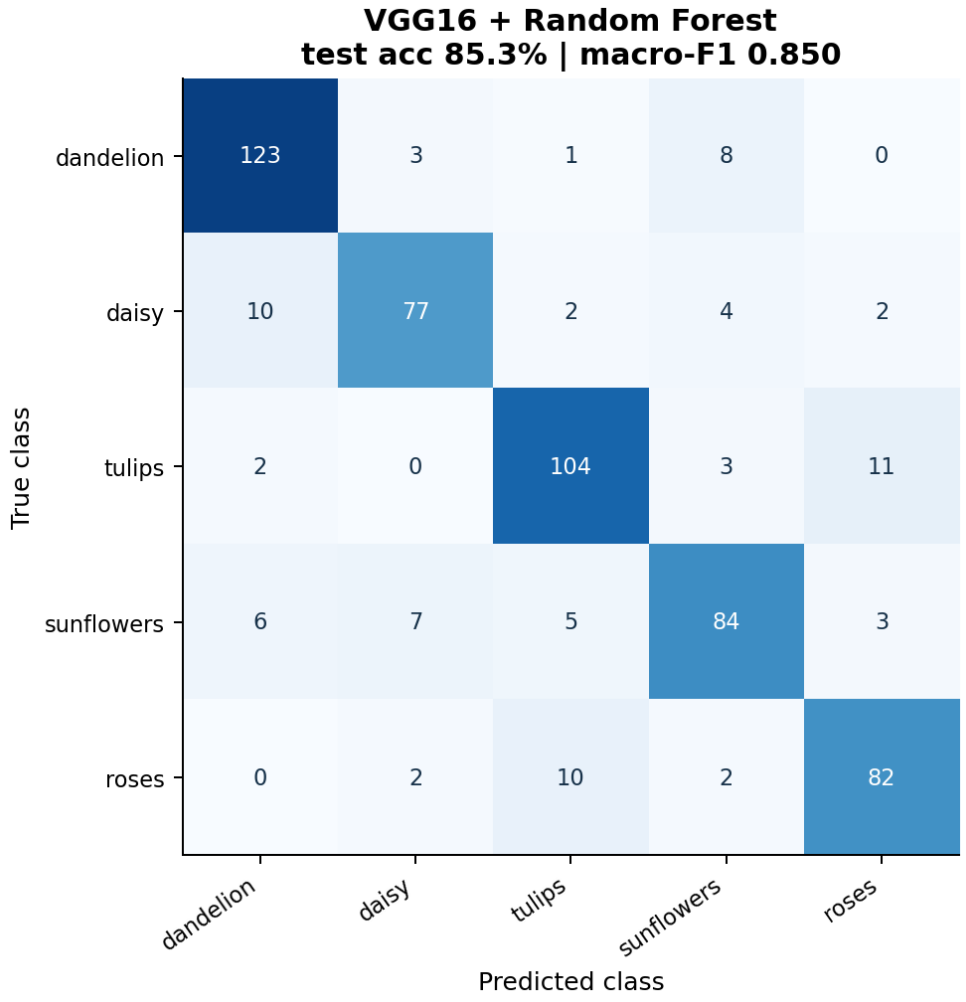


Test: accuracy 85.48%; macro-F1 0.8513; n=551. Рядок - справжній клас, стовпець - прогноз.

Клас	precision	recall	f1-score	support
dandelion	0.9007	0.9407	0.9203	135
daisy	0.9487	0.7789	0.8555	95
tulips	0.8909	0.8167	0.8522	120
sunflowers	0.8673	0.8095	0.8374	105
roses	0.7016	0.9062	0.7909	96

Row-normalized версія: confusion_normalized_vgg16_svm.png. Її діагональ - recall класу.

Матриця: VGG16 + Random Forest



Test: accuracy 85.30%; macro-F1 0.8497; n=551. Рядок - справжній клас, стовпець - прогноз.

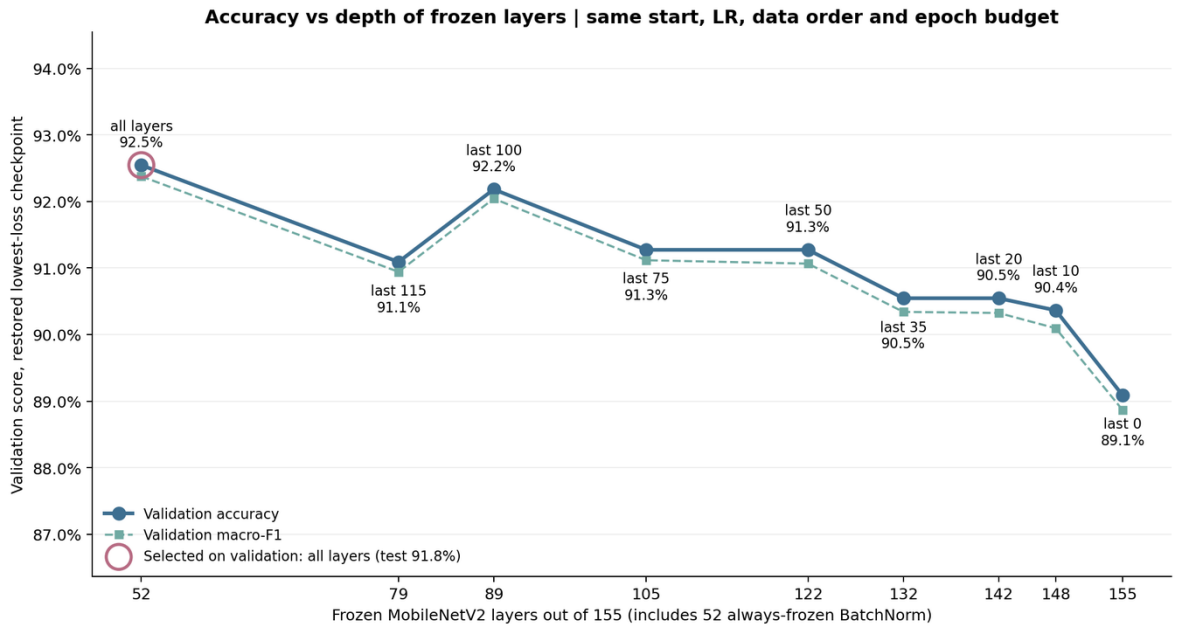
Клас	precision	recall	f1-score	support
dandelion	0.8723	0.9111	0.8913	135
daisy	0.8652	0.8105	0.8370	95
tulips	0.8525	0.8667	0.8595	120
sunflowers	0.8317	0.8000	0.8155	105
roses	0.8367	0.8542	0.8454	96

Row-normalized версія: confusion_normalized_vgg16_randomforest.png. Її діагональ - recall класу.

7. Залежність accuracy від глибини заморожування

MobileNetV2 + Dropout(0.25) + Dense(5, softmax). Спільна голова прогріта 3 епохи з Adam 1e-3. Кожна політика стартує з тієї самої голови та ImageNet backbone, а не продовжує попередній режим.

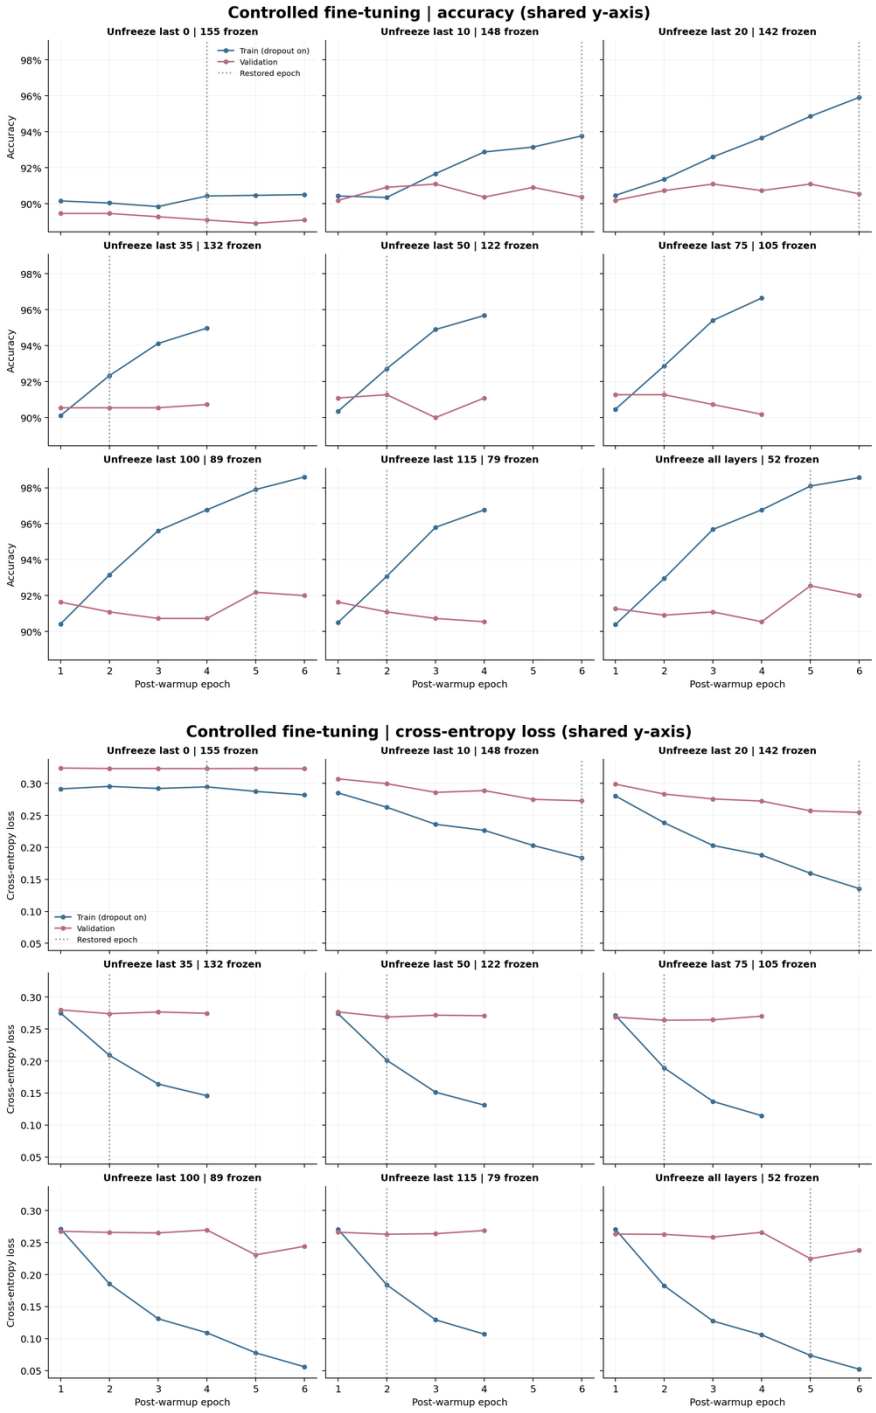
Режим	Frozen	Trainable flags	Шари з вагами	Trainable params	Епохи	Checkpoint	Val acc	Val F1
last 0	155	0	0	0	6	4	89.09%	0.8887
last 10	148	7	3	725 440	6	6	90.36%	0.9009
last 20	142	13	6	1 041 280	6	6	90.55%	0.9032
last 35	132	23	12	1 608 064	4	2	90.55%	0.9034
last 50	122	33	16	1 779 136	4	2	91.27%	0.9107
last 75	105	50	25	2 012 416	4	2	91.27%	0.9112
last 100	89	66	33	2 131 648	6	5	92.18%	0.9204
last 115	79	76	38	2 157 952	4	2	91.09%	0.9094
усі шари	52	103	52	2 189 760	6	5	92.55%	0.9238



Досліджено 9 режимів: від повністю замороженої MobileNetV2 (155 frozen, навчається лише голова) до розморожування всіх шарів, крім 52 BatchNorm (52 frozen). Validation accuracy змінюється від 89.09% до 92.55% (розмах 3.45 в. п.). Head-only дає 89.09%, найкращий режим («усі шари») - 92.55% (+3.45 в. п.). Загальна тенденція: що більше шарів розморожено, то вища точність, але крива немонотонна: перехід last 100 → last 115 знижує accuracy на 1.09 в. п. (6 фото). Різниці в кілька фото на validation з 550 зображень не слід переінтерпретувати.

Вісь X - фактичне число frozen шарів серед 155 шарів backbone, включно з BatchNorm і шарами без ваг. «Last k» - ширина кінцевого вікна, а не кількість навчуваних шарів: у таблиці окремо наведено trainable flags, шари з вагами й параметри.

8. Динаміка навчання режимів



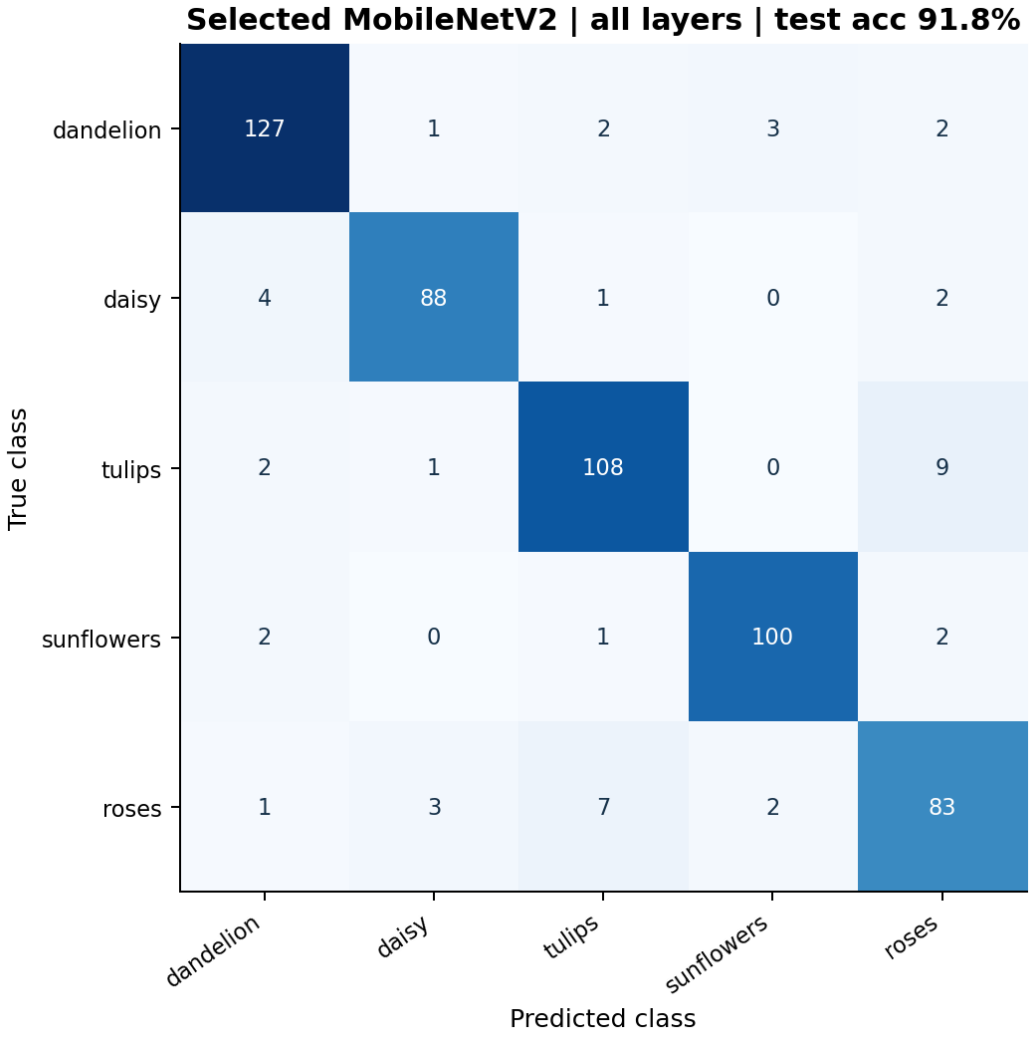
Спільна вісь Y для всіх панелей. Вертикальна лінія - відновлена епоха мінімального val loss. Train accuracy обчислюється з увімкненим dropout. Швидке зростання train accuracy без такого ж росту validation вказує на ризик перенавчання при глибшому розморожуванні.

Потім Adam 1e-5, максимум 6 епох, однакові перестановки train, EarlyStopping(val_loss, patience=2, restore_best_weights=True). Усі 52 BatchNorm frozen, backbone викликається з training=False. Кожен режим перекомпільовано з новим оптимізатором.

Незмінний префікс кешується у float32 (для повного розморожування - сам вхід), trainable суфікс справді донавчається. Враховано всі residual-ребра через межу; еквівалентність із повною мережею перевірено до й після fit. Аугментація відсутня.

9. Фінальна перевірка обраної CNN

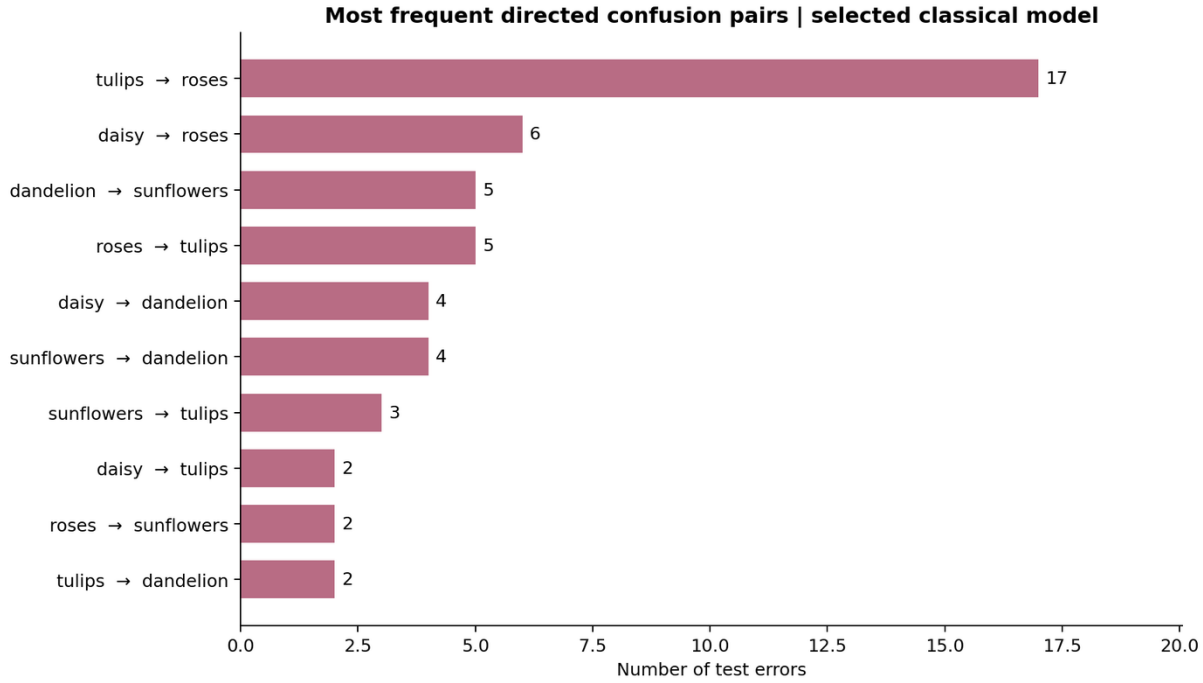
Обрано режим «усі шари»: validation accuracy 92.55%, відновлена епоха 5. Тільки обрана політика отримала фінальну test-перевірку: accuracy 91.83%, macro-F1 0.9171.



Обрана CNN: 506 правильних фото з 551; найкраща з 9 класичних пар - 502 (+4). Це описова різниця одного split; формальної перевірки статистичної переваги не проводили.

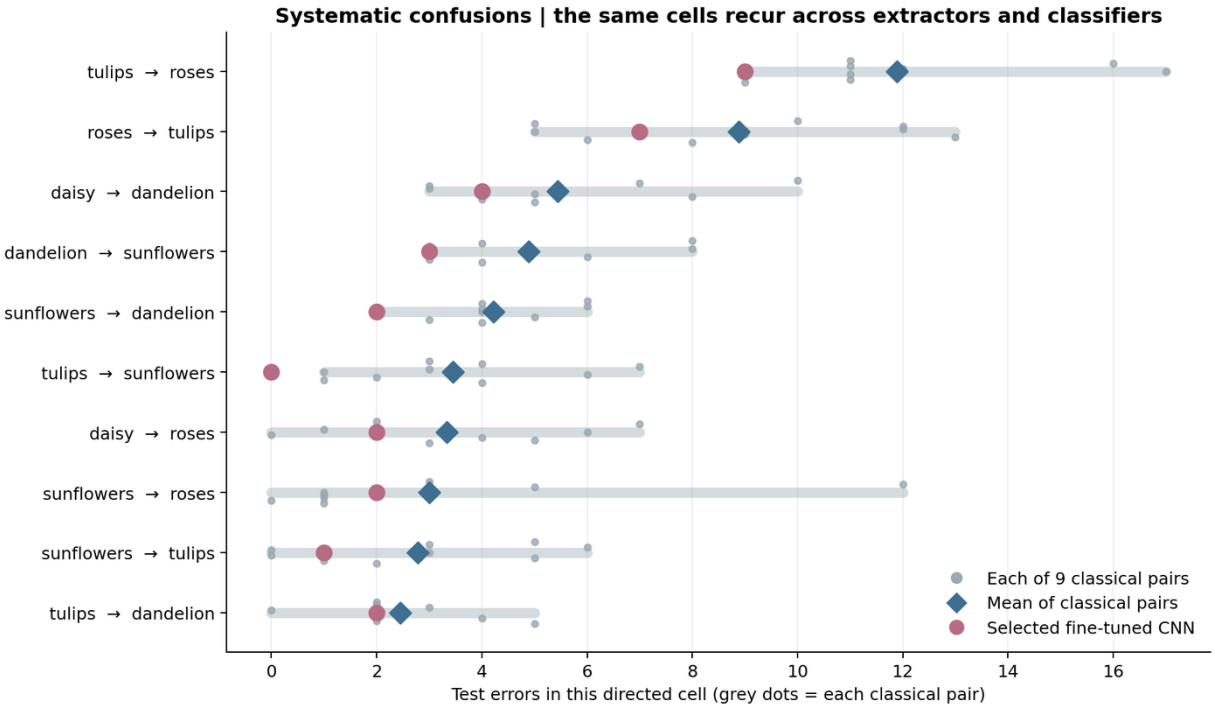
Відтворюваність: режим last 20 повторно навчено на іншій машині для розширення; validation accuracy 90.55% проти 90.55%, macro-F1 0.9032 проти 0.9032.

10. Часті й систематичні пари помилок



Найчастіша пара обраної моделі - tulips → roses: 17 помилок із 120 (14.17%). Зворотний напрям має 5 випадків.

Щоб перевірити, чи помилки систематичні, ті самі клітинки порахували для всіх класичних пар і обраної CNN. Три найчастіші в середньому: tulips → roses (11.9, від 9 до 17; CNN 9); roses → tulips (8.9, від 5 до 13; CNN 7); daisy → dandelion (5.4, від 3 до 10; CNN 4).



11. Реальні приклади хибних прогнозів



flower_03530
True: tulips · Pred: roses
p(pred): 89.7%
Схожі класи



flower_00293
True: daisy · Pred: roses
p(pred): 46.6%
Малий об’єкт / складний фон



flower_02227
True: sunflowers · Pred: dandelion
p(pred): 97.2%
Ракурс, світло або обробка фото



flower_00410
True: daisy · Pred: dandelion
p(pred): 90.3%
Ракурс, світло або обробка фото



flower_01581
True: roses · Pred: tulips
p(pred): 99.7%
Анотація / поза класом



flower_01983
True: roses · Pred: sunflowers
p(pred): 97.8%
Анотація / поза класом

flower_03530: Світлі щільно розташовані пелюстки з рожевими краями, видно одну головку квітки. Візуальна схожість махрового бутона з трояндою; це інтерпретація фото, а не доказ механізму CNN.

flower_00293: Біла ромашка внизу кадру; більшу частину зображення займає собака. Об’єкт займає малу частку кадру, складний фон. Ймовірність рішення 46.6% показує невпевненість.

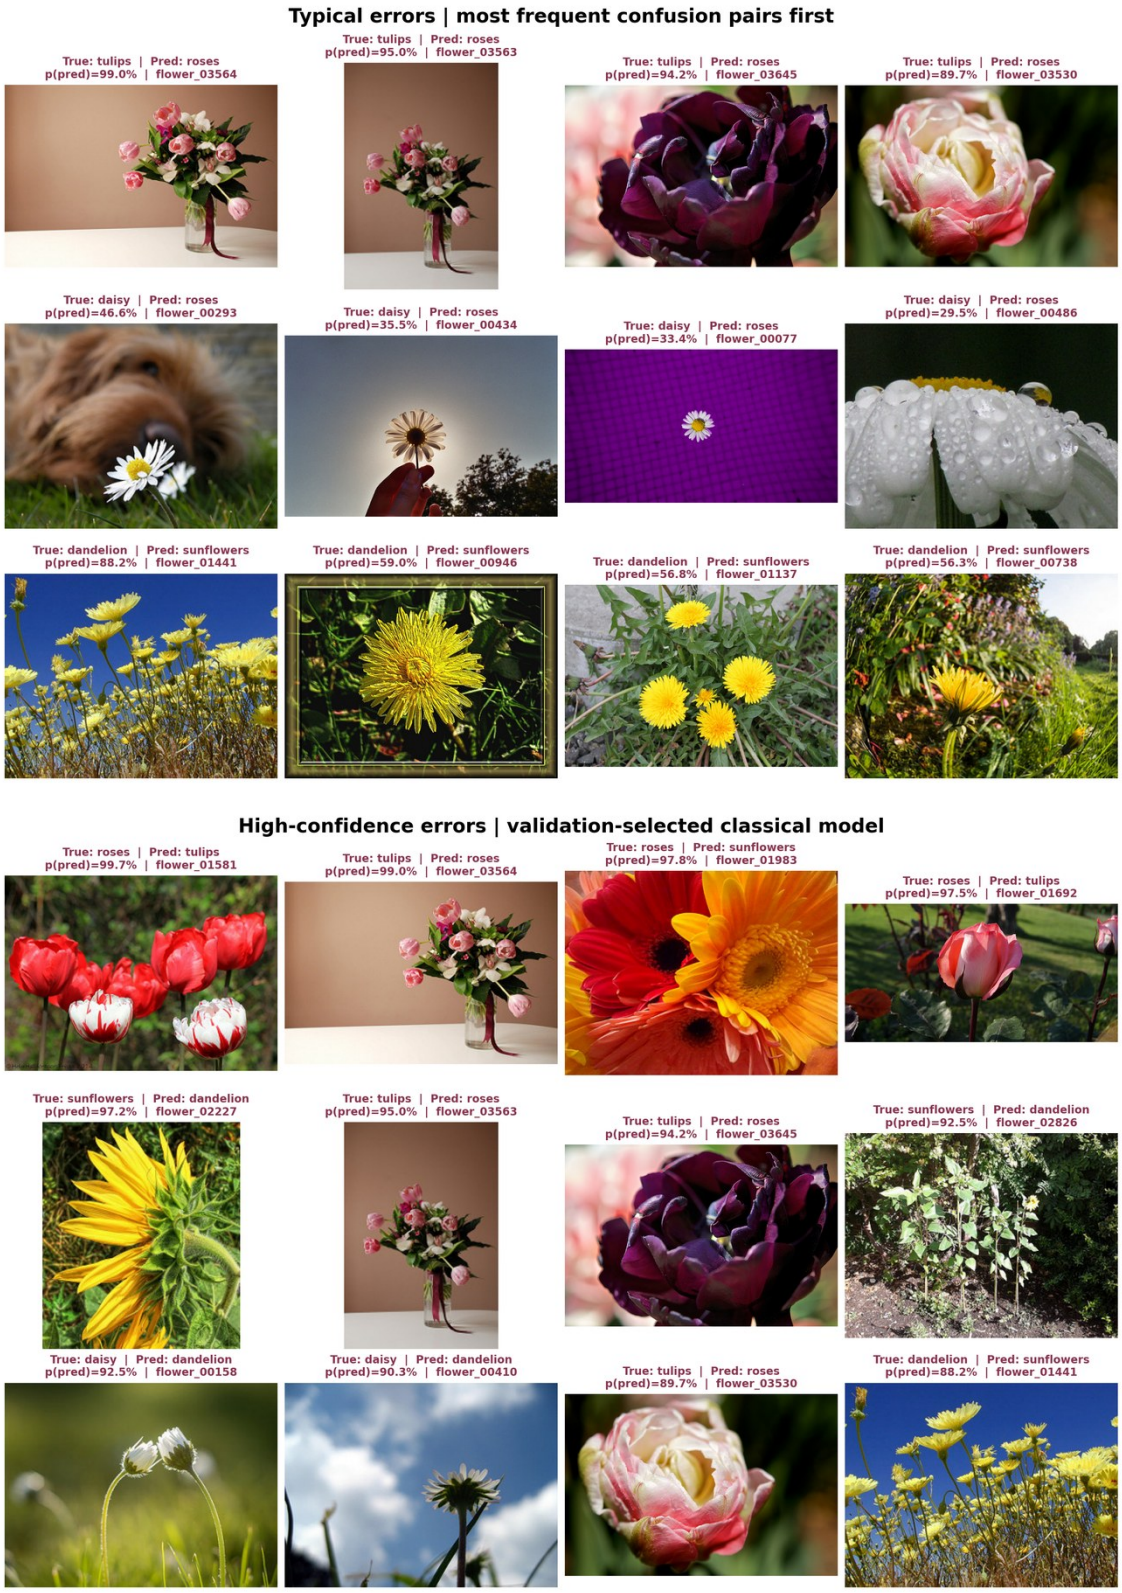
flower_02227: Соняшник знято збоку й ззаду: видно зелені приквітки, центр суцвіття не видно. Нетиповий ракурс прибирає головну ознаку соняшника - великий темний центр; жовті язички нагадують кульбабу.

flower_00410: Ромашка знята знизу на тлі неба, видно зворотний бік суцвіття. Нетиповий ракурс і контрове світло приховують жовтий центр і білі пелюстки.

flower_01581: На фото чітко видно червоні та біло-червоні махрові тюльпани; офіційна мітка roses. Найімовірніше помилка офіційної мітки: модель назвала тюльпани з 99.7%, тобто тут «помилка» моделі може бути правильною відповіддю.

flower_01983: Крупний план червоних і помаранчевих гербер; жодного з п’яти класів у кадрі не видно, офіційна мітка roses. Об’єкт поза п'ятьма класами; модель без reject-класу вибрала найближчий за формою язичкових пелюсток клас sunflowers.

12. Галереї помилок



typical_errors - до чотирьох фото для найчастіших пар; confident_errors - найвпевненіші хибні рішення обраної класичної пари. Повна таблиця описаних фото з категоріями - results/tables/error_observations_ua.csv.

13. Висновки, перевірки й обмеження

1. Порівняно 9 пар екстрактор-класифікатор (3 CNN × 3 класифікатори) на 2569 train / 550 validation / 551 test. Розмір вектора ознак: MobileNetV2 - 1280, ResNet50 - 2048, VGG16 - 512. Єдине розбиття, масштабування лише на train й однакові метрики роблять порівняння узгодженим.

2. За validation macro-F1 вибрано ResNet50 + SVM RBF: validation accuracy 90.91%, validation macro-F1 0.9071. Для цієї зафіксованої пари test accuracy становить 89.84%, macro-F1 - 0.8971 (495 правильних із 551).

3. Найвищу test accuracy серед 9 фіксованих пар показали MobileNetV2 + SVM RBF та ResNet50 + Logistic Regression: 91.11%. Цей описовий результат не використано для перевибору моделі; ranking на validation не зобов’язаний повторитися на test. Середня accuracy validation / test за трьома класифікаторами: ResNet50 90.61% / 90.32%, MobileNetV2 88.97% / 88.69% та VGG16 86.42% / 85.54%. Середня accuracy за трьома екстракторами: SVM RBF 89.27% / 88.81%, Logistic Regression 88.42% / 88.51% та Random Forest 88.30% / 87.24%.

4. Accuracy trend: досліджено 9 режимів: від повністю замороженої MobileNetV2 (155 frozen, навчається лише голова) до розморожування всіх шарів, крім 52 BatchNorm (52 frozen). Validation accuracy змінюється від 89.09% до 92.55% (розмах 3.45 в. п.). Head-only дає 89.09%, найкращий режим («усі шари») - 92.55% (+3.45 в. п.). Загальна тенденція: що більше шарів розморожено, то вища точність, але крива немонотонна: перехід last 100 → last 115 знижує accuracy на 1.09 в. п. (6 фото). Різниці в кілька фото на validation з 550 зображень не слід переінтерпретувати.

5. Обрана за validation CNN (усі шари, checkpoint епохи 5) дала 91.83% test accuracy та 0.9171 macro-F1 (506 правильних із 551). Серед 9 класичних пар максимум був 502/551. Це результати одного split, формально статистичну перевагу не доведено.

6. Найчастіша помилка обраної класичної пари: tulips → roses, 17 фото, тобто 17/120 = 14.17% цього класу; зворотний напрям - 5. Ця ж клітинка є найчастішою й у середньому по всіх 9 класичних парах (11.9 помилки; від 9 до 17), а в обраної CNN - 9. Отже, плутанина tulips/roses систематична, а не випадкова для одного алгоритму.

7. У 17 переглянутих хибних прогнозах виділено причини: ракурс, світло або обробка фото (6), малий об’єкт / складний фон (3), схожі класи (3), анотація / поза класом (3) та кілька видів у кадрі (2). Частина найвпевненіших «помилок» - це, найімовірніше, неточні офіційні мітки або квіти поза п’ятьма класами; модель без reject-класу все одно вибирає один із п’яти.

8. Три пари точних дублікатів не перетинають split; одна пара з різними мітками збережена в train. Обмеження: один seed і split, майже-дублікати не усувалися вичерпно, можливі помилки анотації, немає зовнішнього test і reject-класу.

Виконано автоматичні перевірки (103): відсутність shared hashes між split, узгодженість IDs/labels, перерахунок метрик і матриць із прогнозів, повторне завантаження estimator, train-only scaler, правильний val ranking, зміна лише дозволених ваг CNN і наявність усіх рисунків. Усі пройдено.

14. Середовище, джерела й навігація проєктом

Середовище: Python 3.12, TensorFlow CPU 2.20.0, Keras 3.15.1, scikit-learn 1.8.0, без GPU. Дати запуску: 31.10.2026 (основний запуск) та 01.11.2026 (розширення: VGG16 і додаткові режими заморожування). Час у CSV є журналом запуску, а не строгим speed benchmark.

Обмеження: один seed і один split, скінченний test на 551 фото, можливі майже-дублікати й шум міток, лише п’ять класів, немає external test і reject-класу. Формальної перевірки статистичної переваги не проводили.

Умови викладача, Labs.pdf, слайд 14

https://github.com/dryabokon/Docs/blob/master/ML/Labs.pdf

TFDS TensorFlow Flowers

https://www.tensorflow.org/datasets/catalog/tf_flowers

TFDS: код датасету й порядок міток

https://github.com/tensorflow/datasets/blob/master/tensorflow_datasets/datasets/tf_flowers/tf_flowers_dataset_builder.py

Keras: Transfer learning & fine-tuning

https://keras.io/guides/transfer_learning/

Keras: MobileNetV2

https://keras.io/api/applications/mobilenet/mobilenet_models/

Keras: ResNet

https://keras.io/api/applications/resnet/

Keras: VGG16

https://keras.io/api/applications/vgg/

scikit-learn: model evaluation

https://scikit-learn.org/stable/modules/model_evaluation.html

scikit-learn: t-SNE

https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html

Атрибуція фотографій включена у data/FLOWERS_LICENSE.txt. Оригінал умов і MD-план - у materials/.

Що відкривати на захисті

00_Results_and_Defense.ipynb - готові таблиці й графіки. 01_Transfer_Learning_Flowers.ipynb - код, методика, повторне навчання й прогноз фото. DEFENSE_UA.md - виступ трьох учасників та відповіді. results/figures - усі 36 PNG, включно з 18 окремими матрицями.